3 Stiskanje slik s pomočjo razvrščanja z voditelji

Vseprisotnost multimedijskih vsebin na spletu močno obremenjuje internetno infrastrukturo [28]. Da bi zmanjšali količino prenesenih podatkov se poslužujemo raznovrstnih postopkov za izgubno [23] in brezizgubno [24] stiskanje takih vsebin. Tukaj si bomo ogledali postopek stiskanja s pomočjo razvrščanja z voditelji [25; 26], ki spada med metode nenadzorovanega učenja.

Razvrščanje z voditelji

Razvrščanje z voditelji je metoda, namenjena razvrščanju vzorcev v skupine. Zaradi svoje enostavnosti in robustnosti je zelo razširjena. Za osnovni algoritem je bilo razvitih tudi precej izboljšav in prilagoditev namenjenih reševanju različnih problemov [27].

Recimo, da imamo podano množico n vzorcev $(\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_n)$, kjer je vsak vzorec D-dimenzionalni vektor. Te vzorce želimo razvrstiti v k skupin ali gruč $\mathbf{C} = \{C_1, C_2, C_3, \dots, C_k\}$, kjer je $k \leq n$. Poleg same razvrstitve želimo izračunati še centroide $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_k$, ki predstavljajo povprečen vzorec znotraj posamezne gruče. Razvrščanje v gruče želimo opraviti tako, da minimiziramo raznolikost oziroma varianco znotraj gruče:

$$\underset{\mathbf{C}}{\operatorname{arg\,min}} \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \boldsymbol{\mu}_i\|^2 \quad . \tag{1}$$

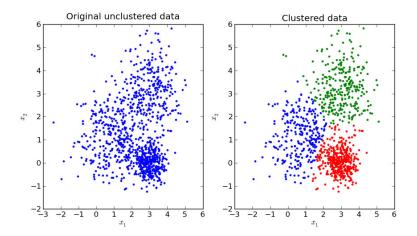
Najbolj običajen algoritem za reševanje tega problema je metoda iterativnega izboljševanja:

```
Inicializiraj začetne vrednosti centroidov \mu_1, \mu_2, \dots, \mu_k tako, da jim prirediš naključen vzorec \mathbf{x}_i while I < Iteracij do for vsak vzorec \mathbf{x}_i do poišči \mu_j z najmanjšo evklidsko razdaljo do \mathbf{x}_i nastavi indeks centroida c_i = j end for for vsak centroid \mu_j do izračunaj povprečje \mathbf{m} vseh \mathbf{x}_i, kjer c_i == j nastavi \mu_j = \mathbf{m} end for end while Polje c vsebuje indekse centroidov za vse vzorce
```

 $\mu_1, \mu_2, \dots, \mu_k$ so končne vrednosti centroidov

Slika 2: Algoritem razvrščanja z voditelji.

Pri razvrščanju se lahko zgodi, da katera izmed gruč ostane prazna. Temu se običajno želimo izogniti. To lahko storimo tako, da prazni gruči pripišemo tisti vzorec, ki je najdlje od svoje trenutne gruče.



Slika 3: Primer razvrščanja 2D vzorcev v tri gruče.

Stiskanje slike

Za zapis pikslov neke slike lahko uporabimo predstavitev RGBA (angl. red, green, blue, alpha) pri čemer uporabimo 8 bitov za zapis intenzitete posameznega barvnega kanala (razpon vrednosti 0–255), skupaj torej 32 bitov na piksel. Število bitov na piksel lahko zmanjšamo, če zmanjšamo število različnih barv v sliki. Naiven pristop je, da enostavno zmanjšamo število razpoložljivih nivojev intenzitete za vsak barvni kanal (na primer iz 256 na 16, kar nam da 16 bitov na piksel) in ustrezno preračunamo nove vrednosti intenzitet. Ta pristop lahko precej pokvari kvaliteto slike. Da bi bolje ohranili informacijo v sliki, je potrebno upoštevati porazdelitev barv v njej.

Ena od možnosti je, da uporabimo razvrščanje z voditelji in podobne barve združimo v gruče, katerih centroide nato uporabimo kot nadomestno barvo za vse piksle znotraj gruče. V tem primeru so naši vzorci piksli - vektorji v štiri-dimenzionalnem prostoru RGBA. Ciljno število različnih barv, ki jih želimo uporabiti v sliki, pa je število gruč v katere razvrščamo piksle. S takim pristopom učinkovito zmanjšamo število različnih barv v sliki in posledično njeno velikost ter bolje ohranimo kvaliteto slike.



(a) Vhodna slika: 32 bitov na piksel.

(b) Izhodna slika: 64 različnih barv (6 bitov na piksel).

Slika 4: Stiskanje slike s pomočjo razvrščanja z voditelji.

Naloga

S pomočjo OpenCL in pthreads/OpenMP napišite vzporedno različico algoritma za stiskanje slik s pomočjo razvrščanja z voditelji. Program naj omogoča stiskanje slik poljubnih velikosti za poljubno število barv. Program naj slike bere in zapisuje v formatu PNG. Za branje in zapisovanje slik lahko uporabite ustrezno knjižnico, na primer STB [29] ali FreeImage [21]. Program naj omogoča izbiro števila niti, ki bodo uporabljene pri procesiranju (OpenMP/pthreads).

Nekaj idej:

- Algoritem ustrezno preoblikujte, da zmanjšate število dostopov do pomnilnika.
- Mogočih je več pristopov k paralelizaciji algoritma. Med niti lahko razdelite vzorce
 ali pa gruče. V večini primerov je prvi pristop boljši, saj je na voljo veliko več
 vzorcev kot gruč.
- Pazite na razporeditev dela, nekatere gruče lahko vsebujejo veliko več vzorcev kot druge.
- Optimizirajte število niti na OpenCL (skupno število niti, število niti na blok).
- Uporabite več grafičnih kartic hkrati.